



Perbandingan Metode ARIMA dan Jaringan Syaraf Tiruan untuk Peramalan Harga Beras

Wahyu Ngestisari^{a,1}, Bambang Susanto^{a,2}, Tundjung Mahatma^{a,3}

^aDepartement Matematika dan Data Sains-Fakultas Sains dan Matematika-Universitas Kristen Satya Wacana, Jl. Diponegoro 52-60, Salatiga 50711, Indonesia

¹662017009@student.uksw.edu; ² bambang.susanto@uksw.edu; ³ tundjung.mahatma@uksw.edu

INFORMASI ARTIKEL	ABSTRAK
<p>Diterima : 09 – 10 – 2020 Direvisi : 12 – 11 – 2020 Diterbitkan : 31 – 12 – 2020</p> <p>Kata Kunci: Harga Beras Peramalan ARIMA Jaringan Syaraf Tiruan</p>	<p>Beras merupakan bahan makanan pokok yang setiap bulannya selalu mengalami kenaikan dan penurunan harga, disebabkan adanya beberapa faktor. Hal ini menimbulkan ketertarikan untuk dilakukannya prediksi harga beras periode selanjutnya. Berdasarkan data rata-rata harga beras bulanan di tingkat grosir pada tahun 2010-2018 yang diperoleh dari situs resmi BPS, fluktuasi harga beras cenderung mengikuti pola musiman. Metode ARIMA merupakan metode yang paling sering digunakan dalam melakukan peramalan data berpola musiman. Metode lain yang dapat digunakan dalam melakukan peramalan harga beras adalah Jaringan Syaraf Tiruan metode <i>Backpropagation</i>. Pada penelitian ini dilakukan perbandingan terhadap kedua metode tersebut untuk menentukan metode yang lebih akurat dalam melakukan peramalan harga beras. Kriteria ukuran kesalahan peramalan yang digunakan untuk mengetahui ketepatan hasil peramalan adalah menghitung <i>Mean Squared Error</i> (MSE) dari data hasil ramalan masing-masing metode dengan data <i>out sample</i> (Januari 2019-Desember 2019). Berdasarkan hasil peramalan dengan metode ARIMA diperoleh model ARIMA terbaik adalah ARIMA (1,1,0) (0,1,1)¹² dengan nilai MSE 51695.36. Sedangkan dengan Jaringan Syaraf Tiruan metode <i>Backpropagation</i> untuk 6 tahun model pelatihan dan 4 tahun untuk model pengujian, diperoleh model arsitektur terbaik adalah JST 12-7-1 dengan nilai MSE 43475.02. Dengan demikian metode yang paling optimal untuk memprediksi harga beras periode selanjutnya adalah JST 12-7-1.</p> <p> </p>

I. Pendahuluan

Indonesia merupakan produsen beras yang cukup besar di dunia yaitu berada di posisi ketiga. Di Indonesia, beras termasuk salah satu bahan makanan pokok yang dikonsumsi setiap hari. Tidak hanya dimanfaatkan untuk diolah menjadi nasi, tetapi beras dapat digunakan sebagai bahan pembuat berbagai macam makanan. Selain itu, beras juga merupakan komoditas strategis yang dominan pada bidang ekonomi seperti kebijakan pemerintah dan sosial politik[1]. Karena beras merupakan komoditas strategis dan politis, maka ketersediaan beras dalam negeri harus terpenuhi. Namun ada beberapa faktor yang mempengaruhi kestabilan ketersediaan beras dan harga beras, seperti kondisi iklim, pola produksi padi, keadaan pasar, naiknya biaya transportasi serta jalur distribusi beras yang panjang dari produsen ke konsumen yang mengakibatkan harga beras setiap bulannya mengalami kenaikan dan penurunan.

Kenaikan harga beras menjadikan masyarakat terpaksa membeli beras dengan harga yang tinggi, karena beras memang merupakan kebutuhan pokok yang wajib dibeli. Untuk itu Pemerintah harus selalu memantau harga kebutuhan bahan pokok, karena seringkali terjadi ketidakstabilan harga di pasar. Penetapan harga barang kebutuhan pokok merupakan salah satu aspek penting yang perlu mendapat perhatian dari pemerintah dan sudah menjadi kewenangan pemerintah untuk menjamin kestabilan harga bahan pokok (Permendag No 71 Tahun 2015). Adanya fluktuasi harga beras yang begitu cepat dan tidak adanya kepastian di masa yang akan datang menuntut pemerintah untuk merumuskan kebijakan harga kebutuhan pokok. Pemerintah dalam menyusun kebijakan kebutuhan harga pokok membutuhkan referensi peramalan harga beras untuk periode selanjutnya. Dengan begitu kenaikan maupun penurunan harga beras yang terjadi di waktu mendatang dapat diantisipasi oleh pemerintah agar dapat dilakukan pengontrolan harga.

Terdapat beberapa metode peramalan yang selama ini digunakan untuk penelitian prediksi harga beras seperti *Moving Average* (MA), Dekomposisi dan *Single Exponential Smoothing*[2]. Agar referensi peramalan harga beras yang digunakan oleh pemerintah memiliki tingkat akurasi yang tinggi, maka dibutuhkan penelitian lanjutan menggunakan metode alternatif lain yang lebih cocok dan akurat dalam meramalkan harga beras. Salah satu metode peramalan yang paling sering digunakan pada kasus data berpola musiman adalah *Autoregressive Integrated Moving Average* (ARIMA). Metode ARIMA merupakan metode yang paling populer dalam peramalan data deret waktu [3]. Metode lain yang dapat digunakan dalam melakukan peramalan harga beras adalah Jaringan Syaraf Tiruan *Backpropagation*. Jaringan Syaraf Tiruan (JST) merupakan suatu sistem pengolahan informasi yang terinspirasi dari sistem kerja syaraf biologis, seperti kinerja otak yang memproses informasi. Algoritma *Backpropagation* merupakan algoritma pembelajaran yang paling populer digunakan dalam melakukan pelatihan jaringan dalam berbagai aplikasi, seperti pemilihan lokasi, pengenalan pola maupun evaluasi kinerja[4]. Jaringan Syaraf Tiruan juga telah berhasil diterapkan dalam proses peramalan di bidang bisnis, pemasaran, industri, dan ilmu pengetahuan [3]. Penelitian ini melakukan perbandingan terhadap kedua metode tersebut untuk menentukan metode yang lebih akurat dalam melakukan peramalan harga beras, sehingga didapatkan nilai peramalan harga beras yang mampu mendekati nilai aktualnya. Perbandingan keakuratan kedua metode tersebut dilakukan berdasarkan nilai kriteria ukuran kesalahan yaitu menghitung nilai *Mean Squared Error* (MSE) dari data hasil prediksi dengan data aktualnya (*out sample*).

II. Metode

A. Peramalan

Peramalan merupakan kegiatan untuk memprediksi mengenai apa yang akan terjadi di masa yang akan datang dengan menggunakan informasi tentang kejadian di masa lalu. Peramalan merupakan alat bantu yang penting dalam perencanaan yang efektif dan efisien [5]. Langkah-langkah dalam melakukan peramalan secara umum adalah pengumpulan data, menyeleksi dan memilih data, memilih model peramalan, menggunakan model terpilih untuk melakukan peramalan, dan evaluasi hasil akhir. Berdasarkan sifatnya, peramalan dibedakan menjadi dua yaitu peramalan kualitatif dan kuantitatif. Metode runtun waktu (*time series*) merupakan salah satu peramalan kuantitatif dengan menggunakan analisa pola hubungan antara variabel yang diperkirakan dengan variabel waktu. Tujuan metode ini adalah menemukan pola data *time series* dengan menggunakan data masa lalu yang akan digunakan untuk meramalkan suatu nilai pada masa yang akan datang. Dalam memilih suatu metode *time series* yang tepat dipertimbangkan jenis plot data, sehingga metode yang paling tepat dengan pola tersebut dapat diuji [5]. Pola data dalam *time series* meliputi Pola Horisontal, Musiman (*Seasonal*), Siklis, dan *Trend*.

Untuk mengetahui keakuratan hasil peramalan dilakukan evaluasi dan validasi metode peramalan. Pada penelitian ini digunakan *Mean Squared Error* (MSE) untuk mengevaluasi hasil peramalan. MSE merupakan metode perhitungan *error* dengan mengkuadratkan nilai *error* pada tiap periode. Pada penelitian ini nilai *error*-nya adalah selisih antara data *out sample* (data target atau data aktual) dengan data hasil prediksi masing-masing metode. MSE dapat dihitung dengan rumus berikut:

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y'_t - Y_t)^2 \quad (1)$$

Keterangan :

Y'_t = nilai target pada waktu ke- t

Y_t = nilai prediksi pada waktu ke- t

n = banyaknya data yang diramalkan

B. Metode Autoregressive Integrated Moving Average (ARIMA)

ARIMA merupakan suatu metode peramalan yang menghasilkan ramalan-ramalan berdasarkan pola data masa lalu. Menurut Arsyad metode Box-Jenkins untuk data runtun waktu (*time series*) yang stasioner adalah ARIMA, dimana metode ini pertama kali diperkenalkan oleh Box-Jenkins pada tahun 1970. Peramalan menggunakan metode ini dilakukan dengan mengabaikan variabel independennya, karena metode ini menggunakan nilai sekarang dan nilai-nilai masa lalu dari variabel dependen untuk menghasilkan peramalan jangka pendek yang akurat[6]. Model yang dapat digunakan termasuk AR, MA, ARMA, ARIMA, dan SARIMA. Jika data mempunyai pola musiman, model yang lebih tepat digunakan adalah *Seasonal Autoregressive Integrated Moving Average* (SARIMA) yang merupakan pengembangan dari model ARIMA pada data runtun waktu yang memiliki pola musiman. Secara umum model Seasonal ARIMA dinotasikan sebagai berikut [7]:

$$ARIMA(p, d, q)(P, D, Q)_s \quad (2)$$

Keterangan :

(p,d,q) = bagian tidak musiman dari model

(P,D,Q) = bagian musiman dari model

S = jumlah periode musiman

Bentuk umum model SARIMA adalah :

$$\phi_p(B)\Phi_P(B^S)(1-B)^d(1-B^S)^DY_t = \theta_q(B)\Theta_Q(B^S) + \varepsilon_t \quad (3)$$

$\phi_p(B)$ = AR non seasonal

$\Phi_P(B^S)$ = AR seasonal

$(1-B)^d$ = differencing non seasonal

$(1-B^S)^D$ = differencing seasonal

$\theta_q(B)$ = MA non seasonal

$\Theta_Q(B^S)$ = MA seasonal

Y_t = nilai data deret waktu ke t

ε_t = residual atau kesalahan

Langkah - langkah menentukan model ARIMA adalah sebagai berikut:

1. Membagi data menjadi *in sample* (108 data pada periode Januari 2010 sampai Desember 2018) dan data *out sample* (12 data mulai Januari 2019 sampai Desember 2019).
2. Menyusun data *in sample*, kemudian di *import* ke dalam *Rstudio*.
3. Membuat plot *time series*, ACF, dan PACF untuk data *in sample* dan melakukan uji *unit root* dengan uji *Augmented Dickey-Fuller* (ADF) untuk mengidentifikasi apakah data sudah stasioner dalam *mean* atau belum. Uji akar unit (*Unit Root Test*) adalah salah satu cara untuk menguji kestasioneran dalam *mean* suatu data runtun waktu. Bentuk umum model ini adalah:

$$Y_t = \delta Y_{t-1} + \varepsilon_t \quad (4)$$

Jika data belum stasioner dalam variansinya maka dilakukan transformasi menggunakan transformasi Box-Cox. Berikut ini adalah persamaan transformasi Box-Cox:

$$T(Y_t) = \frac{Y_t - 1}{\lambda}, \quad \lambda \neq 0 \quad (5)$$

$$T(Y_t) = \ln Y_t, \quad \lambda = 0 \quad (6)$$

4. Membuat plot ACF dan PACF dari data yang sudah stasioner dalam *mean* dan variansi. Kemudian dilakukan identifikasi model dengan menentukan orde AR (p) dan MA (q). Untuk nilai d tergantung dari data, apakah sudah melalui proses *differencing* atau belum. Cara untuk identifikasi orde p dan q dapat dilihat pada Tabel 1 [8].

Tabel 1. Cara Identifikasi Orde

Proses	ACF	PACF
AR (p)	<i>Tails off</i>	<i>Cuts off</i> setelah lag ke p
MA (q)	<i>Cuts off</i> setelah lag ke q	<i>Tails off</i>
AR MA (p,q)	<i>Tails off</i> setelah lag ($q-p$)	<i>Tails off</i> setelah lag ($p-q$)

Tails off artinya, penurunan lag pada plot ACF dan PACF terjadi secara perlahan, sedangkan *Cuts off* adalah penurunan lag terjadi menuju nol setelah lag ke p atau q .

5. Apabila dari plot ACF terlihat memiliki pola lag nyata yang berulang pada lag kelipatan tertentu, maka terdapat unsur musiman. Kemudian lag musiman tersebut diuji kestasionerannya dalam *mean* dengan uji *Augmented Dickey-Fuller* (ADF). Apabila nilai $p\text{-value} > \alpha$ maka lag musiman tidak stasioner dalam *mean*, dan perlu dilakukan *differencing*.
6. Melakukan identifikasi model pada orde AR (p) dan MA (q) non-musiman dan orde AR (P) dan MA (Q) musiman dari grafik ACF dan PACF musiman yang stasioner. Cara untuk identifikasi orde p, q, P, Q

dan Q dapat dilihat pada Tabel 1. Untuk nilai d non musiman dan D musiman tergantung dari data, apakah sudah melalui proses *differencing* atau belum.

7. Melakukan estimasi parameter yaitu pendugaan parameter pada setiap model tentatif dan melakukan uji signifikansi parameter. Rumus *t-hitung* adalah [8]:

$$t - \text{hitung} = \frac{|B|}{SE(\beta)} \quad (7)$$

Dengan ϕ_k adalah parameter dugaan, sedangkan $SE(\beta)$ adalah standar *error* dari setiap parameter dugaan. Hipotesis Uji yang digunakan adalah:

$H_0 : \phi_k = 0$ atau $\theta_k = 0$ (parameter tidak signifikan)

$H_1 : \phi_k \neq 0$ atau $\theta_k \neq 0$ (parameter signifikan)

n : Banyaknya observasi

m : Banyaknya parameter yang ditaksir

Apabila *t-hitung* > *t-tabel* maka H_0 ditolak, artinya parameter signifikan.

8. Melakukan Diagnosa model dari model yang parameternya telah diestimasi dan signifikan untuk melihat model relevan dengan data yang memenuhi asumsi kenormalan dan kebebasan sisaan. Uji kebebasan sisaan model dengan uji asumsi *white noise* menggunakan uji Ljung-box.

Hipotesis:

$H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$

H_1 : minimal ada satu $\rho_k \neq 0$ dengan $k=1,2,\dots,K$

Statistik Uji:

$$Q = n(n+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2}{(n-k)}, \quad n > k \quad (8)$$

Sedangkan uji asumsi residual berdistribusi normal dengan uji Kolmogorov-Smirnov.

Hipotesis:

H_0 : Residual model berdistribusi normal

H_1 : Residual model tidak berdistribusi normal

Apabila nilai *p-value* uji Ljung-Box dan Kolmogorov-Smirnov > α , maka H_0 ditolak, artinya memenuhi kebebasan dan kenormalan sisaan.

9. Memilih model terbaik dengan melihat nilai *Akaike Information Criterion* (AIC) paling kecil.
10. Melakukan peramalan dengan menggunakan model terbaik untuk mengetahui harga beras periode Januari 2019 sampai Desember 2019.

C. Metode Jaringan Syaraf Tiruan (JST)

Jaringan Syaraf Tiruan (JST) atau *Artificial Neural Networks* (ANN) merupakan salah satu sistem pemrosesan informasi yang didesain dengan menirukan cara kerja otak manusia untuk menyelesaikan suatu masalah dengan melakukan proses belajar melalui perubahan bobot dan sinapsisnya. Jaringan Syaraf Tiruan mampu melakukan pengenalan data masa lalu, kemudian data masa lalu tersebut akan dipelajari oleh Jaringan Syaraf Tiruan sehingga akan menghasilkan keputusan terhadap data yang belum pernah dipelajari [9].

Metode Backpropagation

Metode *Backpropagation* merupakan sebuah metode Jaringan Syaraf Tiruan yang menggunakan algoritma pembelajaran (*supervised learning*). Algoritma *Backpropagation* melibatkan tiga lapisan : *input layer* berfungsi memasukkan data ke jaringan, *hidden layer* berfungsi sebagai tempat pemrosesan data dan tempat untuk menentukan jumlah neuron yang akan digunakan, serta *output layer* berfungsi sebagai luaran hasil input [4]. Menurut Haykin 1999, jumlah *hidden neuron* 2 sampai dengan 9 sudah dapat menghasilkan hasil yang baik dalam jaringan, namun pada dasarnya jumlah *hidden neuron* yang digunakan pada Jaringan Syaraf Tiruan dapat berjumlah sampai tak berhingga (∞) [10].

Langkah-langkah menentukan Model Jaringan Syaraf Tiruan Metode *Backpropagation* :

1. Mendefinisikan *input*, *output* dan *hidden layer*. Pada penelitian ini data yang digunakan adalah data bulanan harga beras, berarti periode data dapat diambil selama satu tahun. Jumlah data dalam satu periode ini digunakan sebagai variabel *input* dalam *Backpropagation*. Sebagai variabel *output*nya diambil bulan pertama setelah periode berakhir. Pada data bulanan dengan periode satu tahun, maka *input Backpropagation* yang dipakai terdiri 12 *input* dan 1 *output*. Sedangkan untuk menentukan jumlah *hidden layer* menggunakan jumlah *hidden neuron* 2 sampai dengan 9 [10].
2. Menormalisasikan data ke bentuk sigmoid biner pada lembar kerja (*spreadsheet*), kemudian data di *import* ke dalam *Matlab*. Rumus normalisasi seperti berikut:

$$x' = \frac{0.8(x-b)}{(a-b)} + 0.1 \quad (9)$$

Keterangan :

x' = data hasil normalisasi

x = data awal yang akan dinormalisasi

a = nilai maksimum data awal

b = nilai minimum data awal

3. Membagi data hasil normalisasi menjadi tiga kelompok, yaitu data untuk proses pelatihan (*training*) mulai Januari 2010 sampai Desember 2015, pengujian (*testing*) dari Januari 2015 sampai Desember 2018 dan peramalan mulai Januari 2018 sampai Desember 2019.
4. Memasukkan data *input* untuk proses pelatihan (*training*).
5. Memulai proses pembelajaran prediksi pada data pelatihan (*training*) dengan Jaringan Syaraf Tiruan metode *Backpropagation* dengan langkah sebagai berikut:
 - a. Membuat perancangan model Jaringan Syaraf Tiruan dengan 12 *input*, 1 *output*, dan 2-9 *hidden layer*. Dalam *hidden layer* menggunakan fungsi aktivasi *logsig* dan *purelin*.
 - b. Menentukan bobot dan bias.
 - c. Menentukan nilai parameternya seperti laju pembelajaran (*learning rate*), koefisien momentum dan *epoch*.
 - d. Melakukan prediksi pada data pelatihan dengan mengubah-ubah *hidden layer*nya untuk mencari nilai MSE terkecil yang dipilih sebagai model arsitektur Jaringan Syaraf Tiruan yang akan digunakan pada data pengujian (*testing*).

Tahap perambatan maju (*forward propagation*)

- Setiap unit *input* (x_i , $i = 1, 2, \dots, n$) menerima sinyal *input* x_i dan menyebarkan sinyal tersebut ke seluruh *hidden layer*.
- Pada setiap *hidden layer* (x_j , $j = 1, 2, \dots, p$), menjumlahkan sinyal-sinyal *input* yang sudah berbobot (termasuk biasnya). Rumus mencari *net* dari *input layer* ke *hidden layer* adalah:

$$X_{in_j} = V_{0j} + \sum_{i=1}^n x_i v_{ij} \quad (10)$$

Rumus mencari fungsi aktivasi dari *input layer* ke *hidden layer* adalah:

$$X_j = f(X_{in_j}) \quad (11)$$

- Tiap-tiap unit *output* (Y_k , $k = 1, 2, \dots, m$), menjumlahkan bobot sinyal input. Rumus mencari *net* dari *hidden layer* ke *output layer* adalah:

$$Y_{in_k} = w_{0k} + \sum_{i=1}^n x_i w_{ik} \quad (12)$$

Rumus mencari fungsi aktivasi dari *hidden layer* ke *output layer* adalah:

$$X_j = f(Y_{in_k}) \quad (13)$$

Tahap Perambatan Mundur

- Setiap unit *output* ($Y_k, k = 1, 2, \dots, m$), menerima pola target yang sesuai dengan pola *input* pelatihan, untuk menghitung *error* antara target dengan *output* yang dihasilkan jaringan. Rumus mencari *error* antara target dengan *output* jaringan adalah:

$$\delta_k = (t_k - Y_k) f'(Y_{in_k}) \quad (14)$$

Rumus perubahan koreksi *error* adalah:

$$\Delta w_{jk} = \delta_k \alpha z_j \quad (15)$$

Rumus perubahan koreksi bias adalah :

$$\Delta w_{0k} = \alpha \delta_k \quad (16)$$

- Setiap *hidden layer* ($Z_j, j = 1, 2, \dots, p$) menerima *input* Δ dari langkah ke-6) yang sudah berbobot. Rumus mencari hasil *input* dari *hidden layer* adalah:

$$\delta_{in_j} = \sum \delta_k w_{jk} \quad (17)$$

Rumus mencari hasil *input* dari fungsi turunan aktivasi adalah:

$$\delta_k = \delta_{in_j} f'(z_{in_j}) \quad (18)$$

Rumus mencari koreksi bobot adalah:

$$\Delta v_{ij} = \alpha \delta_j x_i \quad (19)$$

Rumus mencari koreksi bias adalah:

$$\Delta v_{0j} = \alpha \delta_j \quad (20)$$

Tahap Perubahan Bobot dan Bias

- Setiap unit *output* ($Y_k, k = 1, 2, \dots, m$) memperbaiki bobot dan bias dari setiap
- *hidden layer* ($j = 0, 1, \dots, p$). Rumus mencari bobot baru adalah:

$$w_{jk}(\text{baru}) = w_{jk}(\text{lama}) + \Delta w_{jk} \delta_j \quad (21)$$

Setiap *hidden layer* ($Z_j, j = 1, 2, \dots, p$) dilakukan perubahan bobot dan bias ($i = 0, 1, \dots, n$). Rumus mencari bias baru adalah:

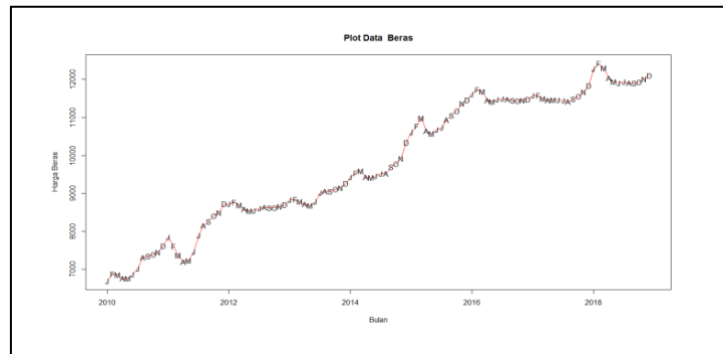
$$v_{ij}(\text{baru}) = v_{ij}(\text{lama}) + \Delta v_{ij} \delta_j \quad (22)$$

- Tes kondisi berhenti apabila *error* ditemukan. Jika kondisi berhenti telah terpenuhi, maka pelatihan jaringan dapat dihentikan.
- Setelah didapatkan model arsitektur jaringan terbaik dari data pelatihan (*training*), kemudian dilakukan uji coba parameter *learning rate* dan *epoch* pada model arsitektur tersebut untuk menghitung MSE terkecil dari data pengujian (*testing*) yang digunakan sebagai model arsitektur yang memiliki parameter optimal untuk melakukan peramalan.
 - Melakukan peramalan dengan model arsitektur terbaik dan parameter optimal untuk prediksi harga beras periode Januari 2019 sampai Desember 2019.

Setelah diketahui hasil prediksi harga beras Januari 2019 sampai Desember 2019 dari masing-masing metode, selanjutnya dapat diketahui metode peramalan terbaik untuk prediksi harga beras periode ke depan. Caranya ialah dengan membandingkan tingkat keakuratan ramalan yang dihasilkan oleh model ARIMA dan Jaringan Syaraf Tiruan *Backpropagation* dengan data *out sample*-nya yang ditinjau dari hasil *Mean Squared Error* (MSE) terkecil dari masing-masing metode.

III. Hasil dan Pembahasan

A. Analisis ARIMA




Gambar 1. Plot Time Series Harga Beras Bulanan di Indonesia


Berdasarkan Gambar 1, menunjukkan bahwa data harga beras mulai Januari 2010 sampai Desember 2018 terlihat adanya fluktuasi dan tidak stabil. Ketidakstabilan tersebut terlihat adanya pola kecenderungan harga yang terus mengalami naik turun. Pola ini mengindikasikan bahwa terdapat komponen musiman pada data harga beras di Indonesia.

Uji Stasioneritas Data

Berdasarkan hasil pengolahan data, hasil transformasi Box-Cox diperoleh nilai $\gamma = 1.99$. Karena nilai γ lebih besar dari 1, sehingga data harga beras dinyatakan stasioner dalam variansi. Selanjutnya berdasarkan hasil uji *Augmented Dickey-Fuller* (ADF) nilai p -value adalah 0.5791 lebih besar dari $\alpha = 0.05$, sehingga data harga beras bulanan tidak stasioner dalam *mean*. Hasil uji ADF diperkuat dengan pengujian terhadap ACF dan PACF. Terlihat dari Gambar 2, ACF berbeda secara signifikan dari nol mengecil secara perlahan membentuk seperti tangga. Sedangkan semua koefisien PACF mendekati nol setelah lag 0. Hal tersebut menunjukkan bahwa data harga beras tidak stasioner dalam *mean*. Oleh karena itu perlu dilakukan *differencing* untuk pertama kali dengan *differencing* orde $d=1$. Nilai p -value hasil uji ADF data hasil *differencing* adalah 0.01 lebih kecil dari $\alpha = 0.05$, sehingga data harga beras bulanan hasil *differencing* stasioner dalam *mean*. Hasil uji ADF diperkuat dengan pengujian terhadap ACF dan PACF data hasil *differencing*. Gambar 3 memberikan gambaran nilai pada setiap lag ACF dan PACF berada pada interval *confidence limit* atau dekat dengan 0 sehingga data setelah *differencing* bersifat stasioner dalam *mean*.

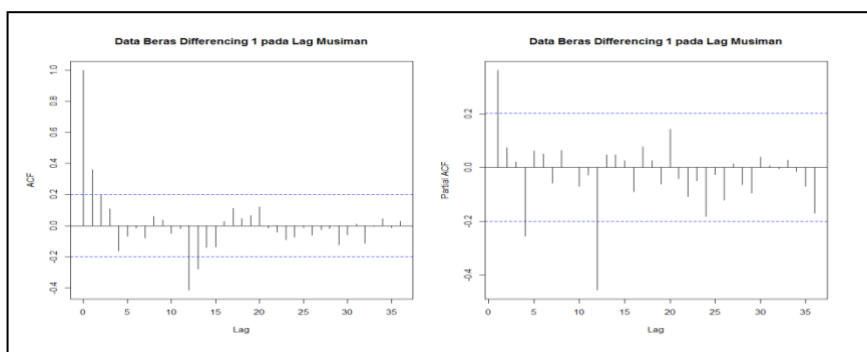


Gambar 2. Plot ACF dan PACF Data Harga Beras



Gambar 3. Plot ACF dan Pacf Data Harga Beras *Differencing* Orde 1
Gambar 4.

Berdasarkan Gambar 3, dapat dilihat bahwa plot ACF memiliki pola *lag* nyata yang berulang pada *lag* kelipatan 12, maka nilai $S = 12$ dan model merupakan SARIMA. Dari hasil uji ADF didapatkan nilai p -value adalah 0.3288 lebih besar dari $\alpha = 0.05$, sehingga *lag* musiman tidak stasioner dalam *mean*, dan perlu dilakukan *differencing*.



Gambar 4. Plot ACF dan PACF *Differencing* Orde 1 pada *Lag* Musiman

Identifikasi Model

Setelah data stasioner dalam *mean* dan variansi, maka dapat dilakukan identifikasi model berdasarkan Tabel 1. Model tentatif SARIMA yaitu kombinasi dari semua identifikasi orde non musiman dan musiman dapat dilihat pada Tabel 2.

Tabel 2. Identifikasi Orde Model SARIMA

Orde Non Musiman	Orde Musiman	Model SARIMA
ARI(1,1,0)	ARI (1,1,0)	ARIMA(1,1,0) (1,1,0) ¹²
	IMA(0,1,1)	ARIMA(1,1,0) (0,1,1) ¹²
	ARIMA(1,1,1)	ARIMA(1,1,0) (1,1,1) ¹²
IMA(0,1,1)	ARI (1,1,0)	ARIMA(0,1,1) (1,1,0) ¹²
	IMA(0,1,1)	ARIMA(0,1,1) (0,1,1) ¹²
	ARIMA(1,1,1)	ARIMA(0,1,1) (1,1,1) ¹²
ARIMA(1,1,1)	ARI (1,1,0)	ARIMA(1,1,1) (1,1,0) ¹²
	IMA(0,1,1)	ARIMA(1,1,1) (0,1,1) ¹²
	ARIMA(1,1,1)	ARIMA(1,1,1) (1,1,1) ¹²

Pendugaan Parameter

Berdasarkan hasil pendugaan parameter, diketahui bahwa model ARIMA(1,1,0) (1,1,0)¹², ARIMA(1,1,0) (0,1,1)¹², ARIMA(0,1,1) (1,1,0)¹² dan ARIMA(0,1,1) (0,1,1)¹² mempunyai $|t\text{-hitung}|$ lebih besar daripada $t\text{-tabel}$ (1.982383) untuk semua parameternya, sehingga model tersebut dikatakan signifikan.

Pemeriksaan Diagnostik

Berdasarkan rumus (8) tentang pemeriksaan diagnostik dengan residual *white noise* dan residual berdistribusi normal, model dikatakan residual *white noise* dan berdistribusi normal apabila nilai *p-value* hasil uji $> \alpha$, dengan $\alpha = 0.05$. Hasil uji Ljung-Box dan Kolmogorov-Smirnov dapat dilihat pada Tabel 3.

Tabel 3. Nilai *p-value* uji Ljung-Box dan Kolmogorov-Smirnov

Model	Ljung-Box	Kolmogorov-Smirnov
ARIMA(1,1,0) (1,1,0) ¹²	0.003381(X)	0.0637(V)
ARIMA(1,1,0) (0,1,1) ¹²	0.5107(V)	0.09446(V)
ARIMA(0,1,1) (1,1,0) ¹²	0.005212(X)	0.05351(V)
ARIMA(0,1,1) (0,1,1) ¹²	0.6368(V)	0.1374(V)

Memilih Model Terbaik

Dari beberapa model yang memenuhi uji signifikansi parameter, uji residual *white noise* dan residual berdistribusi normal, yaitu model ARIMA(1,1,0) (0,1,1)¹² memiliki nilai AIC 1168.07 sedangkan ARIMA(0,1,1) (0,1,1)¹² 1169.76. Oleh karena itu, model ARIMA(1,1,0) (0,1,1)¹² merupakan model terbaik yang akan digunakan untuk melakukan peramalan. Model ARIMA(1,1,0) (0,1,1)¹² dapat ditulis dalam bentuk persamaan sebagai berikut:

$$Y_t = Y_{t-1} + Y_{t-12} - Y_{t-13} + 0.3699Y_{t-1} - 0.3699Y_{t-2} - 0.3699Y_{t-13} + 0.3699Y_{t-14} + \varepsilon_t + 0.778Y_{t-12}$$

B. Analisis Jaringan Syaraf Tiruan (JST)

Normalisasi Data

Pada penelitian ini data yang digunakan adalah data bulanan harga beras mulai Januari 2010 sampai Desember 2019, maka didapatkan sebanyak 120 data. Pada data bulanan dengan periode satu tahun, maka *input Backpropagation* yang dipakai terdiri 12 *input* dan 1 *output*. Pada algoritma Jaringan Syaraf Tiruan *Backpropagation* digunakan fungsi aktivasi sigmoid biner di mana fungsi ini bernilai antara 0 sampai dengan 1, maka data harga beras harus ditransformasikan [0 1]. Tetapi fungsi sigmoid biner nilainya tidak pernah 0 ataupun 1. Oleh karena itu, data harga beras perlu dinormalisasi terlebih dahulu ke dalam range [0.1 0.9] menggunakan rumus (9). Hasil Normalisasi dapat dilihat pada Tabel 4.

Tabel 4. Data Harga Beras Hasil Normalisasi

Tahun	Januari	Februari	...	Desember
2010	0.1	0.126	...	0.228
2011	0.261	0.227	...	0.383
...
2014	0.482	0.496	...	0.61
2015	0.648	0.669	...	0.767
...
2018	0.881	0.9	...	0.857
2019	0.872	0.873	...	0.868

Pembagian Data

Setelah 120 data sudah dinormalisasi, langkah selanjutnya yaitu membagi data menjadi tiga kelompok: data untuk proses pelatihan (*training*), pengujian (*testing*) dan peramalan. Untuk data pelatihan (*training*) sebanyak 72 data yang digunakan mulai Januari 2010 sampai Desember 2015. Pada proses pelatihan dilakukan penentuan variabel menggunakan 72 data tersebut, maka didapatkan 60 data untuk variabel *X input* dan 60 untuk variabel *Y output* atau target. Kemudian untuk data pengujian (*testing*) digunakan 48 data yaitu mulai Januari 2015 sampai Desember 2018. Pada proses pengujian dilakukan penentuan variabel menggunakan 48 data tersebut, maka didapatkan 36 data untuk variabel *X input* dan 36 untuk variabel *Y output* atau target. Sedangkan untuk melakukan peramalan 12 bulan ke depan, yaitu mulai Januari 2019 sampai Desember 2019 dibutuhkan data

untuk mencari variabel *input* sebanyak 12 data. Maka digunakan 24 data mulai Januari 2018 sampai Desember 2019.

Perancangan Model Jaringan Syaraf Tiruan

Dalam proses perancangan model Jaringan Syaraf Tiruan dibutuhkan perintah penetapan bobot dan bias seperti berikut:

1. `net_keluaran.IW{1,1};`
: untuk melihat nilai bobot awal pada lapisan *input* ke *hidden layer* (bilangan diambil secara acak dari komputer)
2. `net_keluaran.b{1,1};`
: untuk melihat nilai bias awal pada lapisan *input* ke *hidden layer* (bilangan diambil secara acak dari komputer)
3. `net_keluaran.LW{2,1};`
: untuk melihat nilai bobot awal pada lapisan *hidden layer* ke *output layer* (bilangan diambil secara acak dari komputer)
4. `net_keluaran.b{2,1};`
: untuk melihat nilai bias awal pada lapisan *hidden layer* ke *output layer* (bilangan diambil secara acak dari komputer)

Adapun *syntax* yang digunakan untuk membuat model Jaringan Syaraf Tiruan *Backpropagation* adalah :

```
net=newff(minmax(data_latih),[HiddenLayer,output],{'logsig','purelin'},'traingdx')
```

Untuk melatih jaringan berdasarkan perintah-perintah yang telah dimasukkan sebelumnya dan melihat hasil yang dikeluarkan oleh jaringan dapat menggunakan perintah seperti berikut:

```
[net_keluaran,tr,Y,E]=train(net,data_latih,target_latih);
```

Proses Pelatihan (*Training*)

Dalam proses pelatihan (*training*) digunakan data *training* yang sudah dinormalisasi. Di dalam proses ini dilakukan pembentukan model dengan cara penentuan jumlah neuron *hidden layer* terbaik dengan melakukan perubahan-perubahan terhadap nilai neuron. Akurasi model ini didapat dari perhitungan nilai MSE terkecil yang didapat dengan perbandingan antara hasil peramalan dengan data actualnya. Pada Tabel 5 diketahui bahwa jumlah neuron *hidden layer* yang terbaik untuk harga beras bulanan di Indonesia yaitu jumlah neuron *hidden layer* sebanyak 7 buah neuron dengan model JST 12-7-1 memiliki nilai MSE terkecil.

Tabel 5. Nilai MSE Harga Beras Proses *Training*

Jumlah Neuron	Model JST	MSE
2	12-2-1	0.00172
3	12-3-1	0.00156
4	12-4-1	0.00208
5	12-5-1	0.00101
6	12-6-1	0.00117
7	12-7-1	0.00089
8	12-8-1	0.00207
9	12-9-1	0.00124

Proses pengujian (*testing*)

Proses pengujian (*testing*) merupakan percobaan peramalan dengan model yang telah didapatkan pada proses pelatihan (*training*) dengan menggunakan data pengujian (*testing*) yang sudah dinormalisasi. Pada proses ini dilakukan uji coba untuk parameter *epoch* dan *learning rate* terhadap model Jaringan Syaraf Tiruan yang didapatkan pada proses pelatihan (*testing*) yaitu JST 12-7-1. Pengujian parameter tersebut akan dicari parameter mana yang menghasilkan nilai MSE terkecil, sehingga didapatkan parameter yang paling optimal untuk melakukan

prediksi. Dari Tabel 6 diketahui bahwa *epoch* 500 dan *learning rate* 0.5 merupakan parameter yang paling optimal pada model JST 12-7-1 dengan MSE = 0.001310.

Tabel 6. Hasil Uji Parameter Harga Beras Proses *Testing*

<i>Epoch</i>	<i>Learning Rate</i>	<i>MSE</i>
500	0.1	0.0014768
100		0.0041629
500	0.2	0.0093087
100		0.0024853
500	0.3	0.0035899
100		0.0019608
500	0.4	0.0087584
100		0.0014397
500	0.5	0.0013104
100		0.0017656
500	0.6	0.0041953
100		0.0090916
500	0.7	0.0016525
100		0.0050420
500	0.8	0.0021121
100		0.0028317
500	0.9	0.0015552
100		0.0014376

Peramalan dengan Metode Terbaik dari ARIMA dan JST

Setelah diketahui model terbaik dari masing-masing metode, maka dapat diketahui model peramalan terbaik untuk prediksi harga beras untuk periode ke depan. Caranya adalah dengan membandingkan tingkat keakuratan ramalan yang dihasilkan oleh model ARIMA(1,1,0) (0,1,1)¹² dan JST 12-7-1 dengan data *out sampelnya* yang ditinjau dari hasil MSE terkecil dari masing-masing metode. Hasil perhitungan akurasi peramalan metode ARIMA dan Jaringan Syaraf Tiruan dapat dilihat pada Tabel 7. Berdasarkan hasil tersebut terlihat bahwa metode Jaringan Syaraf Tiruan *Backpropagation* dengan model JST 12-7-1 dapat dikatakan lebih akurat dalam melakukan peramalan harga beras bulanan di Indonesia untuk periode ke depan.

Tabel 7. Hasil Akurasi Model dengan Data Out Sample untuk Harga Beras 2019

<i>Bulan</i>	<i>Data Out Sample</i>	<i>ARIMA(1,1,0) (0,1,1)¹²</i>	<i>JST 12-7-1</i>
Januari	12211	12304.79	11929
Februari	12222	12369.15	12180.09
Maret	12124	12323.90	12253.07
April	12019	12141.96	12132.37
Mei	12008	12106.45	12021.02
Juni	12009	12149.59	11933.35
Juli	12021	12222.93	11842.5
Agustus	12018	12262.44	11790.18
September	12050	12307.47	11785.95
Oktober	12108	12359.72	11817.71
November	12120	12450.88	11837.69
Desember	12183	12590.05	11887.08
	MSE	51695.3	43475.02

IV. Kesimpulan

Dari hasil peramalan menggunakan metode ARIMA dan Jaringan Syaraf Tiruan di atas, didapatkan bahwa metode yang paling cocok dan lebih akurat untuk memprediksi harga beras di Indonesia pada periode yang akan datang adalah metode Jaringan Syaraf Tiruan *Backpropagation* dengan model JST 12-7-1 menggunakan nilai *epoch* 500 dan *learning rate* 0.5 dengan MSE 43475.02. Penelitian lanjutan yang akan dilakukan adalah dengan memperbanyak jumlah *neuron hidden layer* dan uji coba parameter pada metode Jaringan Syaraf Tiruan *Backpropagation*, agar didapatkan model peramalan yang lebih akurat.

Daftar Pustaka

- [[1] A. R. Yanuarti and M. D. Afsari, "Profil Komoditas Barang Kebutuhan Pokok Dan Barang Penting Komoditas Beras," 2016, p. 44.
- [2] K. Sukiyono and R. Rosdiana, "Pendugaan Model Peramalan Harga Beras Pada Tingkat Grosir," *J. AGRISEP*, vol. 17, no. 1, pp. 23–30, 2018, doi: 10.31186/jagrisep.17.1.23-30.
- [3] R. Ristiana, "Perbandingan arima dan jaringan syaraf tiruan propagasi balik dalam peramalan tingkat inflasi nasional radita ristiana," 2015.
- [4] Y. Andriani, H. Silitonga, and A. Wanto, "Analisis Jaringan Syaraf Tiruan untuk prediksi volume ekspor dan impor migas di Indonesia," *Regist. J. Ilm. Teknol. Sist. Inf.*, vol. 4, no. 1, p. 30, 2018, doi: 10.26594/register.v4i1.1157.
- [5] V. K. Laura, "Peramalan Banyaknya Penabung Di Credit Union Sumber Kasih Teraju Dengan Metode Box Jenkins," 2018.
- [6] L. R. Sasongko, L. N. Rahayu, and A. R. Kota, "Penentuan Model Peramalan Indeks Harga Saham Gabungan dengan Metode Arima," *Pros. Semin. Nas. Sains dan Pendidik. Sains UKSW*, pp. 786–796, 2010.
- [7] Z. Kafara, F. Y. Rumlawang, and L. J. Sinay, "Peramalan Curah Hujan Dengan Pendekatan Seasonal Autoregressive Integrated Moving Average (Sarima)," *BAREKENG J. Ilmu Mat. dan Terap.*, vol. 11, no. 1, pp. 63–74, 2017, doi: 10.30598/barekengvol11iss1pp63-74.
- [8] N. Istiqomah, "Prediksi Kemunculan Titik Panas Di Provinsi Riau Menggunakan Seasonal Autoregressive Integrated Moving Average (Sarima)," p. 19, 2015.
- [9] M. T. P. Manalu, "Jaringan Syaraf Tiruan untuk Memprediksi Curah Hujan Sumatera Utara dengan Metode Back Propagation (Studi Kasus : BMKG Medan)," *JURIKOM (Jurnal Ris. Komputer)*, vol. 3, no. 1, pp. 35–40, 2016.
- [10] N. Amalina, "Penerapan Metode Artificial Neural Networks Untuk Meramalkan Nilai Ekspor Migas Dan Non Migas Di Indonesia," 2016.
- [11] Azis. Adriamin, Izzati. Munifatul, and Haryanti. Sri, "Aktivitas Antioksidan dan Nilai Gizi dari Beberapa Jenis Beras dan Millet sebagai Bahan Pangan Fungsional Indonesia," *Jurnal Biologi*, vol 4, no. 1, pp. 45-61, 2015.
- [12] Bobby. Akbar, "Peramalan Nilai Impor Non Migas di Jawa Timur dengan Menggunakan Metode ARIMA BOX-JENKINS," 2017.
- [13] Cynthia. Eka Pandu and Ismanto. Edi, "Jaringan Syaraf Tiruan Algoritma Backpropogation dalam Memprediksi Ketersediaan Komoditi Pangan Provinsi Riau," *Jurnal Teknologi dan Sistem Informasi Univrab (RABIT) Universitas Muhammadiyah Riau*, vol 2, no. 2, pp. 196-209, 2017.
- [14] M. Andi Alfian Fadila, "Aplikasi Jaringan Syaraf Tiruan dalam Memprediksi Penjualan Mobil pada PT. Hadji Kalla Sengkang," 2017.
- [15] Gunaryati. Atris, Fauziah and Andryana. Septi, "Perbandingan Metode-metode Peramalan Statistika untuk Data indeks Harga Pangan," *Jurnal Universitas Nasional*, vol 2, no. 3, pp. 241- 248, 2018.
- [16] Sumarjaja. Wayan, "Analisis Deret Waktu," 2016.